LISTA 7 EXTRA

ALUNO: Caio Gomes Alcântara Glória

MATRICULA: 763989

PROFESSORA: Cristiane Neri

Questão 1)

CODIGO NO LINK:
https://github.com/KYOgomes/IA/blob/main/Listas/Lista7/1perceptron.py

Questão 2)
CODIGO NO LINK:
https://github.com/KYOgomes/IA/blob/main/Listas/Lista7/2backpropagation.py

2.1) Importância da Taxa de Aprendizado

A taxa de aprendizado (α\alphaα) controla o tamanho dos passos que o algoritmo de Backpropagation dá ao ajustar os pesos com base no gradiente calculado. É essencial porque:

- **Taxa Muito Alta**: O modelo pode nunca convergir para o mínimo global, oscilando ao redor da solução ótima devido aos passos grandes demais.
- **Taxa Muito Baixa**: O modelo pode levar um tempo excessivamente longo para convergir, ou até mesmo ficar preso em mínimos locais.

Investigação Experimental: Teste o treinamento da rede com valores diferentes de α\alphaα (ex.: 0.001, 0.01, 0.1, 0.5). Observe o impacto no erro final e no número de épocas necessárias para convergência.

Conclusão Geral: Uma taxa de aprendizado adaptada ao problema e à arquitetura é crucial. Otimizadores como Adam e RMSProp ajustam dinamicamente a taxa de aprendizado durante o treinamento.

2.2) Importância do Bias

O bias é um termo adicional que permite deslocar a função de ativação, aumentando a flexibilidade do modelo. Ele é fundamental para redes neurais porque:

- Sem bias, a rede é restrita a passar a origem no espaço de entrada, o que limita sua capacidade de modelar dados complexos.

- Bias introduz uma "liberdade de deslocamento" no hiperplano da rede, ajudando a melhorar o ajuste aos dados.

Investigação Experimental: Treine o modelo com bias e sem bias para um mesmo problema lógico (ex.: AND com 3 entradas). Compare os erros e a convergência.

Conclusão Geral: Bias é indispensável para que redes possam aprender padrões não lineares.

2.3) Funções de Ativação e Relevância da Derivada

Funções de ativação introduzem não linearidade, permitindo à rede aprender relações complexas. Exemplos e suas características:

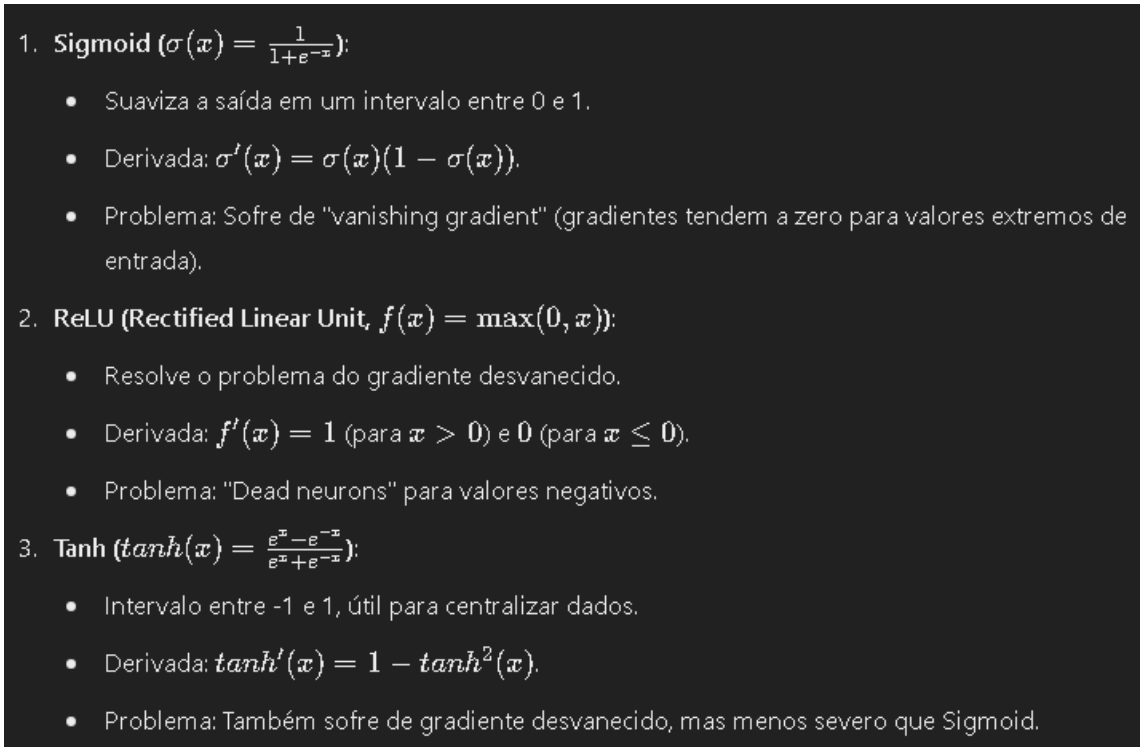

2.4) Função de Ativação Não Linear no Backpropagation

A não linearidade é essencial porque:

- **Modelagem de Relações Complexas**: Redes com funções de ativação lineares são matematicamente equivalentes a um único neurônio, independentemente do número de camadas. Isso limita severamente a capacidade de modelar relações complexas nos dados.

- **Separação de Hiperplanos**: Funções não lineares, como ReLU ou Sigmoid, permitem que a rede crie limites de decisão mais complexos, adaptando-se melhor a problemas não linearmente separáveis (ex.: XOR).

Investigação Experimental: Compare os resultados do Backpropagation com funções de ativação linear (ex.: $f(x)=xf(x) = xf(x)=x$) versus não linear (ex.: ReLU) em problemas como XOR.

Conclusão Geral: A não linearidade permite que a rede aprenda múltiplas representações internas dos dados, transformando-os em cada camada e aumentando a capacidade de generalização.

Questão 3)

BRANCO